Introdução ao Python

MBA USP/ESALQ

Anotações por Lucas Rezende

Manipulação de base de dados

Utilização do numpy e pandas

Importando dados de um arquivo .csv

In [6]:
```
import pandas as pd
import numpy as np

df = pd.read_csv('(2) notas_pisa.csv', sep=",", decimal=".")  # lê um arquivo .csv

df['country']  # podemos nos referenciar a uma coluna do data frame como se fosse u
```

Out[6]:
```
0                      Australia
1                        Austria
2                        Belgium
3                         Canada
4                          Chile
                  ...
91    Ukraine (18 of 27 Regions)
92          United Arab Emirates
93                       Uruguay
94                    Uzbekistan
95                      Viet Nam
Name: country, Length: 96, dtype: object
```

In [7]:
```
df['country'][0]
```

Out[7]:
```
'Australia'
```

read_csv has many parameters that allow you to customize how the CSV is read. Some of the most commonly used ones are:

- sep: Specify a custom delimiter, e.g., sep=';' if your CSV uses semicolons.
- header: Specify which row to use as the column names. For example, header=0 uses the first row.
- index_col: Specify which column to use as the row labels of the DataFrame. For example, index_col=0 uses the first column.
- usecols: Specify a subset of columns to read. For example, usecols=['col1', 'col2'].

- dtype: Specify the data type for the columns. For example, dtype={'col1': int, 'col2': float}. na_values: Specify additional strings to recognize as NA/NaN. For example, na_values=['NA', '?'].

Importando dados de um arquivo xlsx

In [8]:
```
df = pd.read_excel('(2) receita_empresas.xlsx')  # podemos utilizar a função read_e
```

Criação de Data Frames

Podemos criar o nosso próprio data frame, seguindo a estrutura de um dicionário:

In [9]:
```
varA = pd.Series(['a','b','c','d','e','f'])  # criando uma série, que será uma colu
varB = pd.Series([1, 2, 3, 4, 5, None])
varC = np.arange(1, 7)  # podemos utilizar o numpy também

df2 = pd.DataFrame({'varA': varA,  # criando o Dataframe no estilo de um dicionário
                    'varB': varB,
                    'varC': varC})

df2
```

Out[9]:

	varA	varB	varC
0	a	1.0	1
1	b	2.0	2
2	c	3.0	3
3	d	4.0	4
4	e	5.0	5
5	f	NaN	6

In [10]:
```
df3 = pd.DataFrame({'VarA': ['Brasil', 'Estados Unidos', 'Peru', 'Colômbia', 'Urugu
                    'VarB': [1, 2, 3, 4, 5],
                    'varC': ['Inativo', 'Ativo', 'Ativo', None, 'Ativo']})
df3
```

Out[10]:

	VarA	VarB	varC
0	Brasil	1	Inativo
1	Estados Unidos	2	Ativo
2	Peru	3	Ativo
3	Colômbia	4	None
4	Uruguai	5	Ativo

Salvando Data Frames (Exportar base de dados)

Salvando em CSV

Utilizamos a função to_csv

- path_or_buf: String or file handle, default None. The file path or object to write. If not specified, the result is returned as a string.
- sep: String, default ','. The delimiter to use. For example, sep='\t' for tab-separated values.
- na_rep: String, default ''. The string representation of missing values.
- float_format: String, default None. Format string for floating-point numbers. For example, float_format='%.2f' will format numbers with two decimal places.
- columns: Sequence, optional. Columns to write. If not specified, all columns are written.
- header: Boolean or list of strings, default True. Whether to write column names. If a list of strings is given, it is used as the column names.
- index: Boolean, default True. Whether to write row names (index).
- index_label: String or sequence, default None. Column label for the index column(s). If None, the index names are used.
- mode: String, default 'w'. The file mode to use ('w' for write, 'a' for append).
- encoding: String, default None. The encoding to use for the output file, e.g., encoding='utf-8'.
- compression: String or dict, default None. For on-the-fly compression of the output file. Possible values: 'infer', 'gzip', 'bz2', 'zip', 'xz', or a dict with specific options.
- quoting: Constant from csv module, default csv.QUOTE_MINIMAL. Controls when quotes should be generated by the CSV writer.
- quotechar: String, default '"'. Character to use for quoting fields.
- line_terminator: String, default None. The newline character or sequence to use in the output file.
- chunksize: Integer, default None. Write file in chunks of this size.
- date_format: String, default None. Format string for datetime objects.
- doublequote: Boolean, default True. Control whether quoting is done with double quotes.
- escapechar: String, default None. Character to use for escaping the sep and quotechar if quoting is set to csv.QUOTE_NONE.
- decimal: String, default '.'. Character recognized as decimal separator. E.g., use ',' for European data.

In [11]:
```
df3.to_csv('Data Frame 3.csv', index=False)  # essa função salva o arquivo em CSV

# index = False diz para não escrever os índices no arquivo.
```

Salvando em xlsx

Utilizamos a função to_excel

Key Parameters

- excel_writer: This can be a string representing the file path, a pandas.ExcelWriter object, or a file-like object.
- sheet_name: Specifies the name of the sheet where the DataFrame will be written. The default is 'Sheet1'.
- na_rep: String representation for missing values. For example, na_rep='N/A'.
- float_format: Format string for floating-point numbers. For example, float_format='%.2f'.
- columns: A list of column names to write. If not specified, all columns are written.
- header: Boolean or a list of strings. If True, the column names are written. If False, no header is written. You can also pass a list of column names to be used as the header.
- index: Boolean. If True, the index is written to the file. The default is True.
- index_label: A string or a sequence. The column label(s) for the index column(s). If None, the index name(s) are used.
- startrow: The upper left cell row to start writing the DataFrame data. The default is 0.
- startcol: The upper left cell column to start writing the DataFrame data. The default is 0.
- engine: Specify the Excel writer engine to use. Options are None, 'xlwt', 'xlsxwriter', 'openpyxl', 'odf', 'pyxlsb'. The default is None, meaning pandas will choose the appropriate engine based on the file extension.
- merge_cells: Boolean. Write MultiIndex and Hierarchical Rows as merged cells. The default is True.
- encoding: The encoding of the output file. The default is utf-8.
- inf_rep: Representation for infinity values (inf). The default is inf.
- verbose: If True, prints additional information. The default is False. freeze_panes: A tuple (row, col) for the topmost row and leftmost column to be frozen. For example, freeze_panes=(1, 1).

In [12]:
```
df2.to_excel('Data Frame 2.xlsx', index=False)
```

Aula III - Introdução ao Python

Métodos e funções do dataframe

df.info()

Traz informações sobre o objeto em questão

In [13]:
```
import pandas as pd
import numpy as np
```

```
df = pd.read_csv('(2) notas_pisa.csv', delimiter=",")
print(df.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 96 entries, 0 to 95
Data columns (total 8 columns):
 #   Column            Non-Null Count  Dtype 
---  ------            --------------  ----- 
 0   country           96 non-null     object
 1   group             96 non-null     object
 2   mathematics_2022  96 non-null     object
 3   reading_2022      96 non-null     object
 4   science_2022      96 non-null     object
 5   mathematics_2018  96 non-null     object
 6   reading_2018      96 non-null     object
 7   science_2018      96 non-null     object
dtypes: object(8)
memory usage: 6.1+ KB
None
```

df.iloc()

Localiza um elemento com base na posição, as contagens se iniciam no 0, tanto em linha quanto coluna

In [14]:
```
df.iloc[0, 3];  # imprime o elemento da linha 0, coluna 3 (Linha 1 coluna D)
```

In [15]:
```
df.iloc[0:7];  # imprime da linha 0 a 7 (linha 1 a 8)
```

In [16]:
```
df.iloc[:, [0, 2, 5]];  # imprime todas as linhas mostrando apenas as colunas 0, 2,
```

In [17]:
```
df.iloc[:, 0:3]; # imprime todas as linhas, das colunas 0 até 2 (A até C)
```

df.reindex()

Troca a ordem dos índices da base de dados

pd.to_numeric(df['coluna'])

Transforma a coluna em dados números

`arg` : O argumento a ser convertido. Pode ser uma lista, série, ou um array-like (incluindo colunas de um DataFrame).

`errors` : Define como lidar com erros durante a conversão. Pode assumir três valores:

- raise: (padrão) Levanta uma exceção se houver um erro na conversão.
- coerce: Converte os valores que não puderem ser convertidos para NaN.
- ignore: Retorna o argumento original sem alterações se houver um erro.

`downcast` : Uma tentativa de converter valores para o tipo numérico de menor tamanho possível, para economizar memória. Pode assumir os valores:

- integer: Converte para o tipo de inteiro de menor tamanho possível.
- signed: Converte para o tipo de inteiro assinado de menor tamanho possível.
- unsigned: Converte para o tipo de inteiro não assinado de menor tamanho possível.
- float: Converte para o tipo de ponto flutuante de menor tamanho possível.

In [18]:
```
df['mathematics_2018'] = pd.to_numeric(df['mathematics_2018'], errors='coerce')
df['reading_2018'] = pd.to_numeric(df['reading_2018'], errors='coerce')
df['science_2018'] = pd.to_numeric(df['science_2018'], errors='coerce')


df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 96 entries, 0 to 95
Data columns (total 8 columns):
 #   Column            Non-Null Count  Dtype  
---  ------            --------------  -----  
 0   country           96 non-null     object 
 1   group             96 non-null     object 
 2   mathematics_2022  96 non-null     object 
 3   reading_2022      96 non-null     object 
 4   science_2022      96 non-null     object 
 5   mathematics_2018  78 non-null     float64
 6   reading_2018      77 non-null     float64
 7   science_2018      78 non-null     float64
dtypes: float64(3), object(5)
memory usage: 6.1+ KB
```

Repare como que a coluna de dados mathematics_2018 contém dados do tipo float

df.drop()

Podemos excluir dados utilizando linhas ou colunas como parâmetros, bem como o índice

In [19]:
```
df.drop(df.index[18:96]);  # excluindo todos os dados da linha 18 até a linha 95
```

df.dropna()

Exclui observações que continham valores faltantes

In [20]:
```
df_na = df.dropna()
df_na;
```

df.describe()

Extrai estatísticas descritivas das variáveis métricas

In [21]:
```
df[['mathematics_2018', 'reading_2018', 'science_2018']].describe()
```

Out[21]:

	mathematics_2018	reading_2018	science_2018
count	78.000000	77.000000	78.000000
mean	458.671675	453.101877	457.915065
std	56.456544	53.131971	51.941188
min	325.100547	339.691591	335.629947
25%	417.470322	412.295085	417.326482
50%	467.964344	465.950148	468.155673
75%	499.941059	498.279257	498.277673
max	591.393598	555.236244	590.452641

df.value_counts()

Conta os valores em uma determinada coluna

In [22]:
```
df['group'].value_counts()
```

Out[22]:
```
group
PARTNERS    58
OECD        38
Name: count, dtype: int64
```

pd.crosstab()

In [79]:
```
pd.crosstab(index=df['pais'], columns='Países')
```

Out[79]:

pais	col_0 Países
Albania	1
Albania (2015)	1
Algeria	1
Argentina	1
Argentina (2015)	1
...	...
United Kingdom	1
United States	1
Uruguay	1
Uzbekistan	1
Viet Nam	1

96 rows × 1 columns

Filtros

É possível filtrar observações por meio dos operadores: Alguns operadores úteis para realizar filtros:

- == igual
- > maior
- >= maior ou igual
- < menor
- <= menor ou igual
- != diferente
- & indica e
- | indica ou

In [23]:
```
df[df['mathematics_2018'] > 430]; # filtra todos as linhas que contém notas de mate

df[df['mathematics_2018'] > 430][0:4] # podemos mostrar apenas os primeiros 4 resul
```

Out[23]:

	country	group	mathematics_2022	reading_2022	science_2022	mathema
0	Australia	OECD	487.08425354734698	498.05093978372099	507.000869417628	4
1	Austria	OECD	487.26749908879401	480.40584721829902	491.27095877058503	4
2	Belgium	OECD	489.48681680184899	478.852668384217	490.57834610681402	5
3	Canada	OECD	496.94789438732198	507.13289582796602	515.01667592948297	5

In [24]:
```
df[df['group'] == 'OECD']; # mostra apenas os valores do data frame que tem OECD na
```

Mesclando critérios

In [25]:
```
df['science_2022'] = pd.to_numeric(df['science_2022'], errors = 'coerce');
df[(df['group'] == 'OECD') & (df['science_2022'] <= 493)];  # utilizando a notação
df[(df['group'] == 'OECD') | (df['science_2022'] <= 493)];  # utilizando a notação
```

Agrupando banco de dados

df.groupby(by['coluna'])

Agrupa o data frame de acordo com os grupos. Por exemplo, numa base de dados com salários dos funcionários, é possível agrupar o df de acordo com o gênero.

In [26]:
```
df_agrupado = df.groupby(by=['group'])  # df_agrupado não pode ser manipulado da me
df_agrupado.describe()
```

Out[26]:

	count	mean	std	min	25%	50%	75%	sc
group								
OECD	37.0	484.646614	30.989428	409.886598	477.463366	491.270959	499.964883	
PARTNERS	44.0	415.147382	52.110795	347.104162	375.607585	406.984551	433.148079	

2 rows × 32 columns

Transpondo uma tabela de dados

In [27]:
```
df_agrupado.describe().T  # podemos transpor a tabela
```

Out[27]:

	group	OECD	PARTNERS
science_2022	**count**	37.000000	44.000000
	mean	484.646614	415.147382
	std	30.989428	52.110795
	min	409.886598	347.104162
	25%	477.463366	375.607585
	50%	491.270959	406.984551
	75%	499.964883	433.148079
	max	546.634453	561.433275
mathematics_2018	**count**	38.000000	40.000000
	mean	486.998322	431.761360
	std	33.563272	60.824943
	min	390.932273	325.100547
	25%	481.241544	394.197636
	50%	495.766955	421.875066
	75%	507.878070	451.291620
	max	526.973250	591.393598
reading_2018	**count**	37.000000	40.000000
	mean	485.487406	423.145262
	std	27.108257	53.920935
	min	412.295085	339.691591
	25%	473.974317	391.847911
	50%	491.800785	413.926415
	75%	503.928109	441.658446
	max	523.017018	555.236244
science_2018	**count**	38.000000	40.000000
	mean	486.740274	430.531117
	std	28.796369	54.416865
	min	413.322993	335.629947
	25%	475.460431	397.513395
	50%	492.807054	424.917405

group	OECD	PARTNERS
75%	503.285090	444.052998
max	530.108005	590.452641

df.sort_values(by=['coluna'])

In [28]:
```
df['mathematics_2018'].sort_values()[0: 5] # podemos ordenar apenas uma coluna
```

Out[28]:
```
55    325.100547
80    352.567068
77    352.846256
65    365.884947
74    367.727353
Name: mathematics_2018, dtype: float64
```

In [29]:
```
df.sort_values(by=['mathematics_2018'])[0: 5]  # ordenando a base de dados inteira
```

Out[29]:

	country	group	mathematics_2022	reading_2022	science_2022	mathema
55	Dominican Republic	PARTNERS	339.10724671520001	351.31228660018098	360.426060	3
80	Philippines	PARTNERS	354.71971267011003	346.547387252531	356.167293	3
77	Panama	PARTNERS	356.57350389273603	391.953355235988	387.767624	3
65	Kosovo	PARTNERS	354.96244390817299	342.19442056258799	357.024052	3
74	Morocco	PARTNERS	364.766240669848	339.36492493384299	365.398076	3

In [30]:
```
df.sort_values(by=['mathematics_2018'], ascending= False)[0:5]  # Aqui eu não coloc
```

Out[30]:

	country	group	mathematics_2022	reading_2022	science_2022	mathema
49	B-S-J-Z (China)	PARTNERS	—	—	NaN	59
86	Singapore	PARTNERS	574.663819557029	542.55332240961297	561.433275	56
67	Macao (China)	PARTNERS	551.92315308368097	510.40512187447899	543.096281	55
59	Hong Kong (China)	PARTNERS	540.35180120700602	499.701340798594	520.418680	55
52	Chinese Taipei	PARTNERS	547.09416419952095	515.16728997095902	537.380381	53

Renomeando o data frame

In [31]:
```
nomes = ["pais",
         "grupo",
         "matematica_2022",
         "leitura_2022",
         "ciencias_2022",
         "matematica_2018",
         "leitura_2018",
         "ciencias_2018"]

df.columns = nomes  # mudando o nome das variáveis

df[0:1]
```

Out[31]:

	pais	grupo	matematica_2022	leitura_2022	ciencias_2022	matematica_20
0	Australia	OECD	487.08425354734698	498.05093978372099	507.000869	491.3600

In [32]:
```
df.columns.array[1] = 'grupos_países'  # mudando o nome de apenas uma coluna
```

Visualização de dados

In [33]:
```
#!pip install matplotlib;
#!pip install seaborn;
#!pip install plotly;
```

In [34]:
```
import matplotlib.pyplot as plt
import seaborn as sns
import plotly.express as px
import plotly.io as pio
pio.renderers.default = 'browser'
import plotly.graph_objects as go
```

In [35]:
```
comercio = pd.read_excel('(2) comercio_global.xlsx')
```

seaborn.countplot(data = df, x= 'coluna')

Consegue contar dados categóricos e fazer um gráfico de contagens

Parameters

- `x, y` : Names of variables in data or vector data, optional. One of these variables should be specified to determine the position of the bars.
- `hue` : Name of variable in data or vector data, optional. If specified, will produce a multi-plot grid by different levels of the hue variable.
- `data` : DataFrame, array, or list of arrays, optional. The data source.
- `order` : List of strings, optional. Order to plot the categorical levels in; otherwise, the levels are inferred from the data objects.

- `hue_order` : List of strings, optional. Order to plot the levels of the hue variable in; otherwise, the levels are inferred from the data objects.
- `orient` : “v” or “h”, optional. Orientation of the plot (vertical or horizontal). This is usually inferred based on the type of the input variables, but it can be used to resolve ambiguity when both x and y are numeric or when plotting wide-form data.
- `color` : Matplotlib color, optional. Color for all elements, or seed for a gradient palette.
- `palette` : Palette name, list, or dict, optional. Colors to use for the different levels of the hue variable.
- `saturation` : Float, optional. Proportion of the original saturation to draw colors at.
- `dodge` : bool, optional. When hue nesting is used, whether elements should be shifted along the categorical axis.
- `ax` : Matplotlib Axes, optional. Axes object to draw the plot onto, otherwise uses the current Axes.
- `kwargs` : Other keyword arguments are passed through to seaborn.catplot

Dica: `hue` é utilizado para produzir plots divididos em categorias. Por exemplo, produzir plots de contagens de frequência de alunos pelo dia da semana (variável x) separados por gênero (hue='gênero')

In [36]:
```
sns.countplot(data = comercio, x='market')
```

Out[36]:
```
<Axes: xlabel='market', ylabel='count'>
```

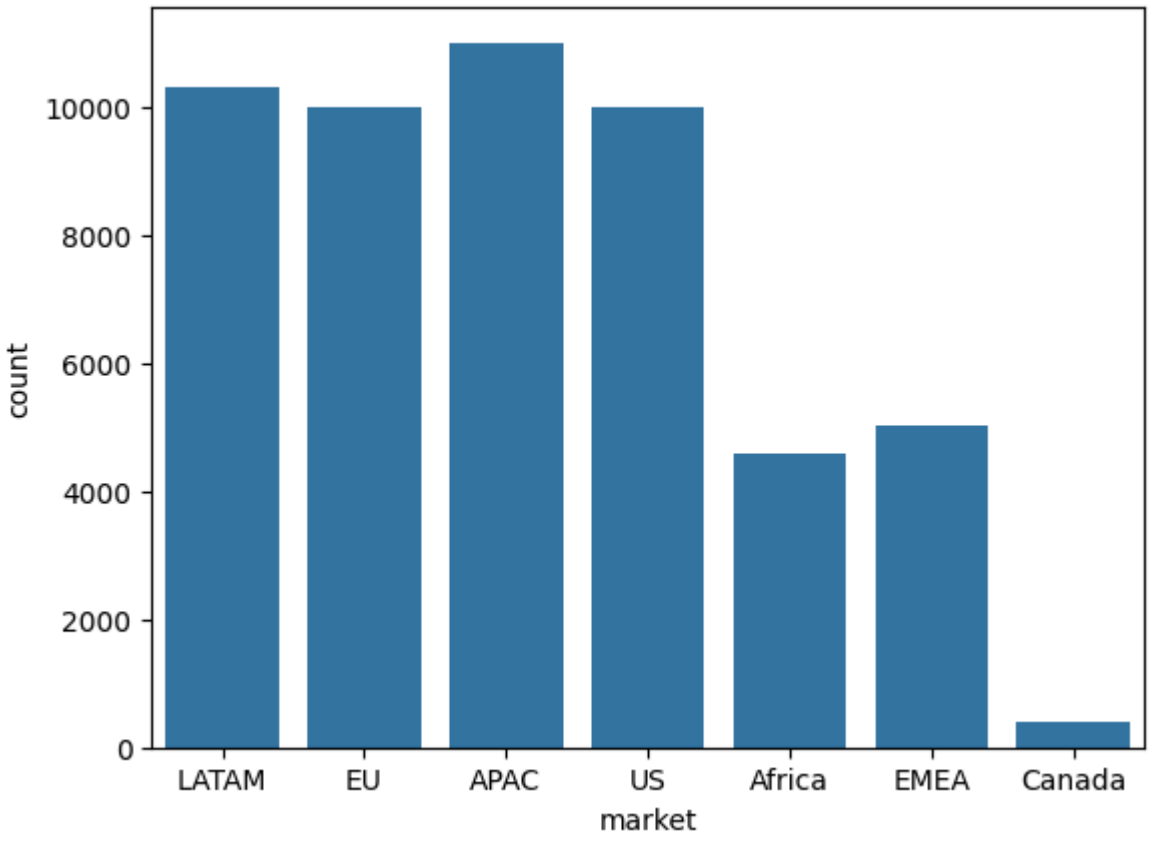

In [37]:
```
# podemos ordenar os dados e implementar cores

sns.countplot(data = comercio, x='market', order=["APAC", "LATAM", "EU", "US", "Afr
```

Out[37]:
```
<Axes: xlabel='market', ylabel='count'>
```

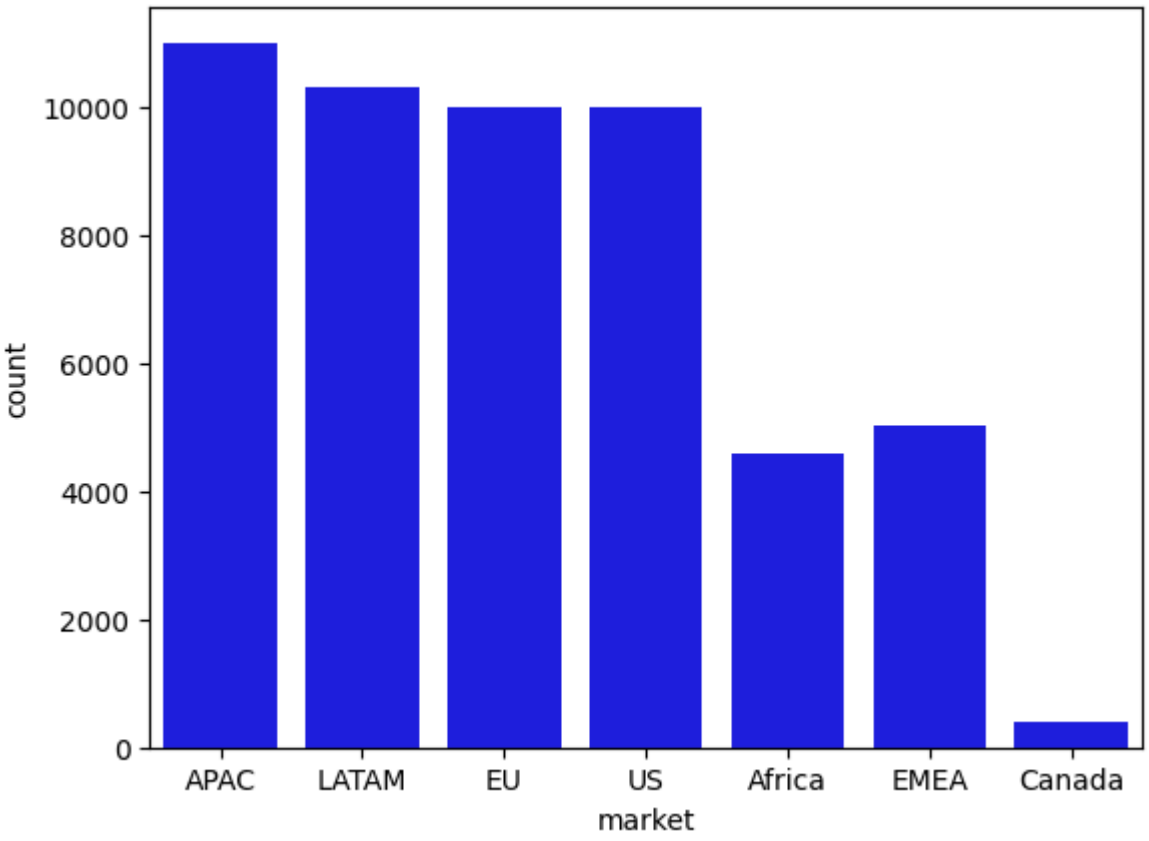

Adicionando mais formatação

Podemos utilizar a `matplotlib.pyplot` para adicionar mais informações ao gráfico

In [38]:
```
sns.countplot(data = comercio, x='market', order=["APAC", "LATAM", "EU", "US", "Afr
plt.title("Análise por Mercado")
plt.xlabel('Mercado',fontsize=12)
plt.ylabel('Conatgem',fontsize=12)
plt.show()
```

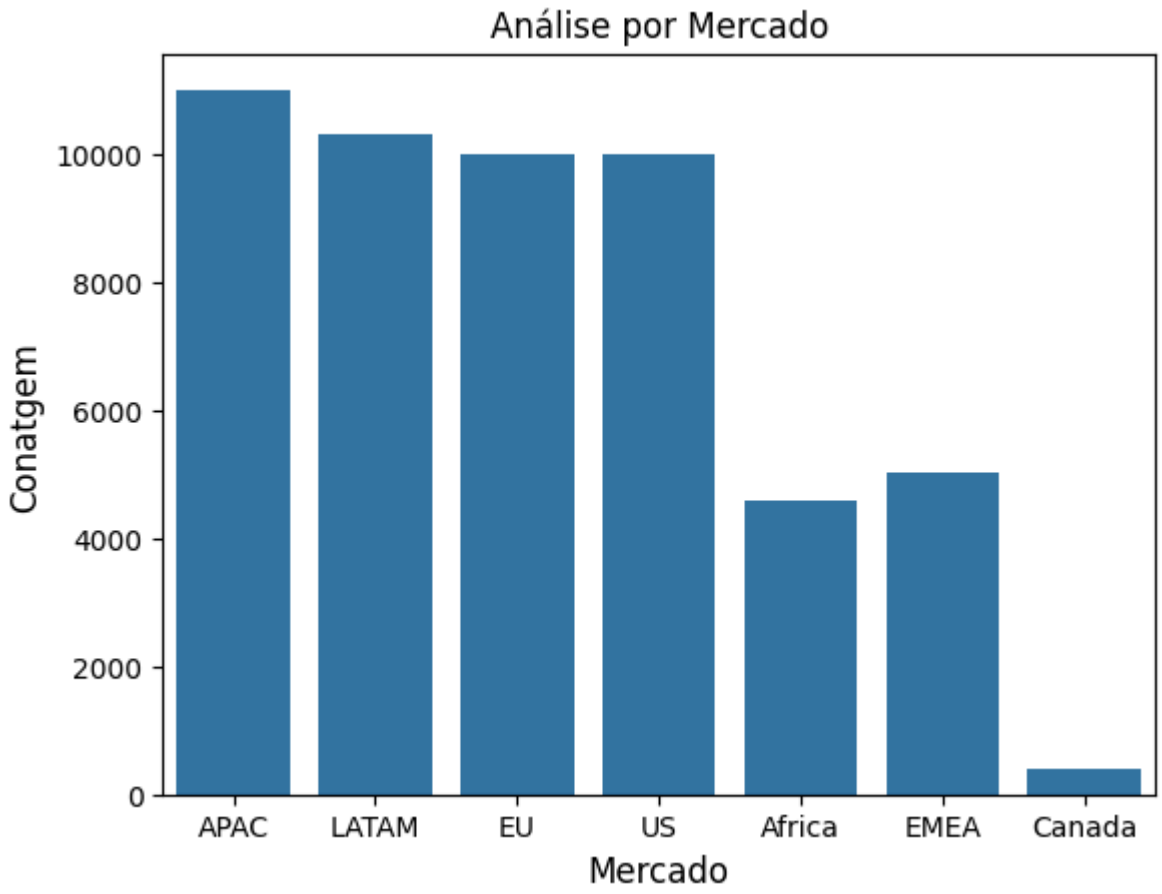

Paleta de cores

A biblioteca seaborn vem com algumas paletas de cores

Paleta bright

In [39]:
```
# Paleta bright

palette = sns.color_palette("bright")
sns.palplot(palette)
```

Paleta viridis

In [40]:
```
palette = sns.color_palette("viridis")
sns.palplot(palette)
```

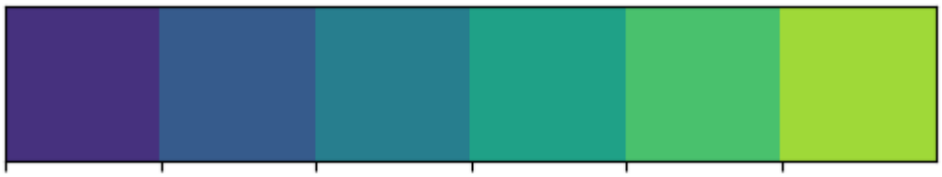

Paleta Paired

In [41]:
```
palette = sns.color_palette("Paired")
sns.palplot(palette)
```

Paleta Rocket

In [42]:
```
palette = sns.color_palette("rocket")
sns.palplot(palette)
```

Podemos utilizar a paleta de cores no nosso plot

In [43]:
```
ax = sns.countplot(data=comercio, x="market",hue="market",order=["APAC", "LATAM", "
ax.bar_label(ax.containers[0], fontsize=8)
plt.title("Análise por Mercado")
plt.xlabel('Mercado',fontsize=12)
plt.ylabel('Conatgem',fontsize=12)
plt.show()
```

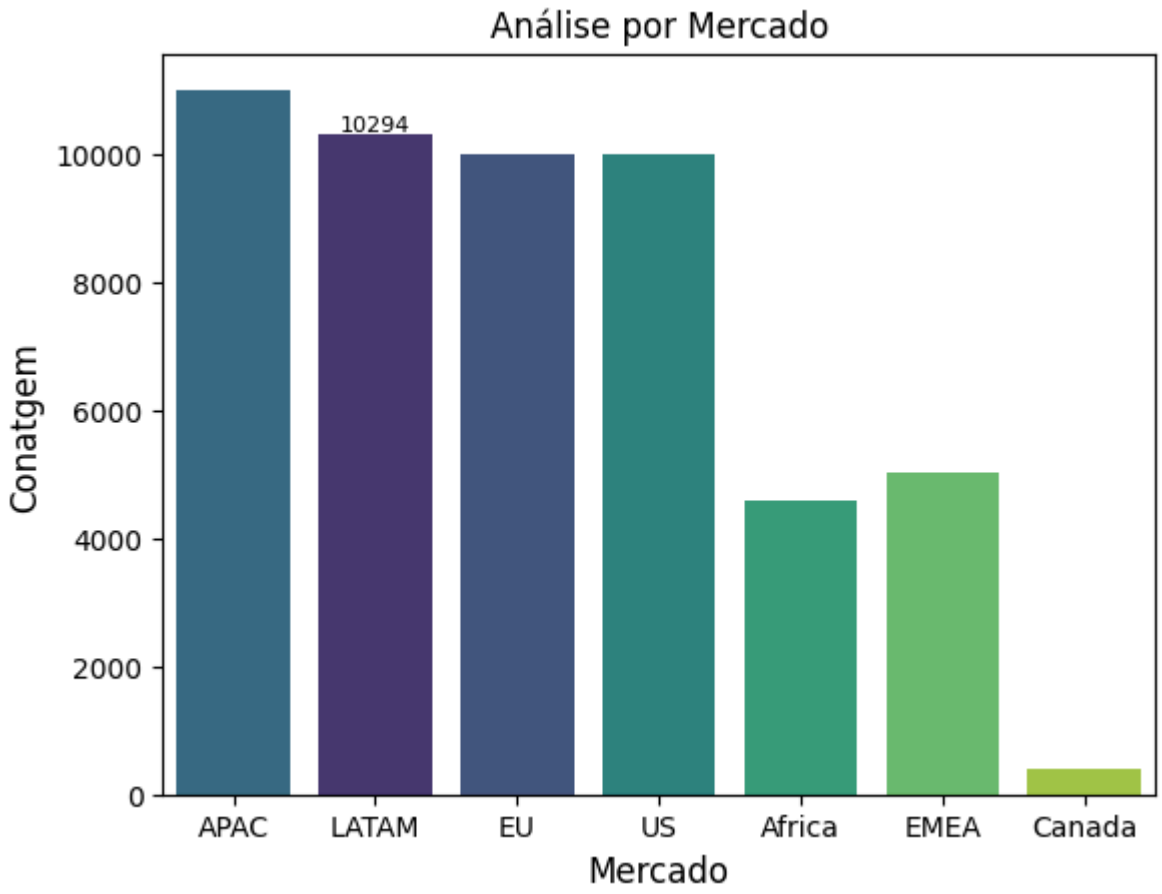

Salvando o objeto plt

In [44]:
```
ax = sns.countplot(data=comercio, x="market",hue="market", order=["APAC", "LATAM",
ax.bar_label(ax.containers[0], fontsize=8)
plt.title("Análise por Mercado")
plt.xlabel('Mercado',fontsize=12)
plt.ylabel('Conatgem',fontsize=12)
plt.show()
```

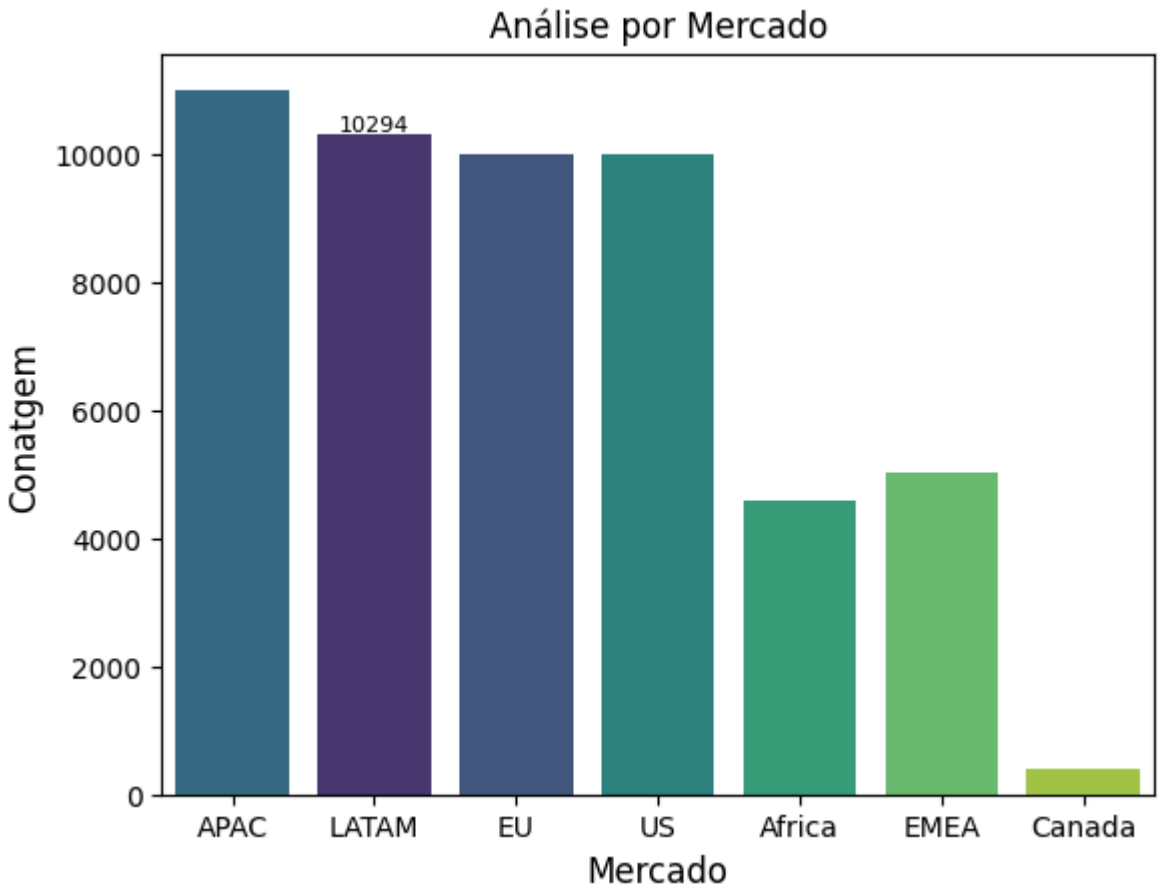

Invertendo a ordem do gráfico

In [45]:
```
comercio['market'].value_counts(ascending=False)  # contagem de dados
```

Out[45]:
```
market
APAC      11002
LATAM     10294
EU        10000
US         9994
EMEA       5029
Africa     4587
Canada      384
Name: count, dtype: int64
```

In [46]:
```
comercio['market'].value_counts(ascending=False).index  # ordena os labels em ordem
```

Out[46]:
```
Index(['APAC', 'LATAM', 'EU', 'US', 'EMEA', 'Africa', 'Canada'], dtype='object', n
ame='market')
```

In [47]:
```
ax = sns.countplot(data=comercio, y="market",
                   order = comercio['market'].value_counts(ascending=False).index,
                   palette = 'viridis',
                   hue = "market")
ax.bar_label(ax.containers[0], fontsize=8)
plt.title("Análise por Mercado")
plt.xlabel('Contagem',fontsize=12)
```

```
plt.ylabel('Mercado',fontsize=12)
plt.show()
```

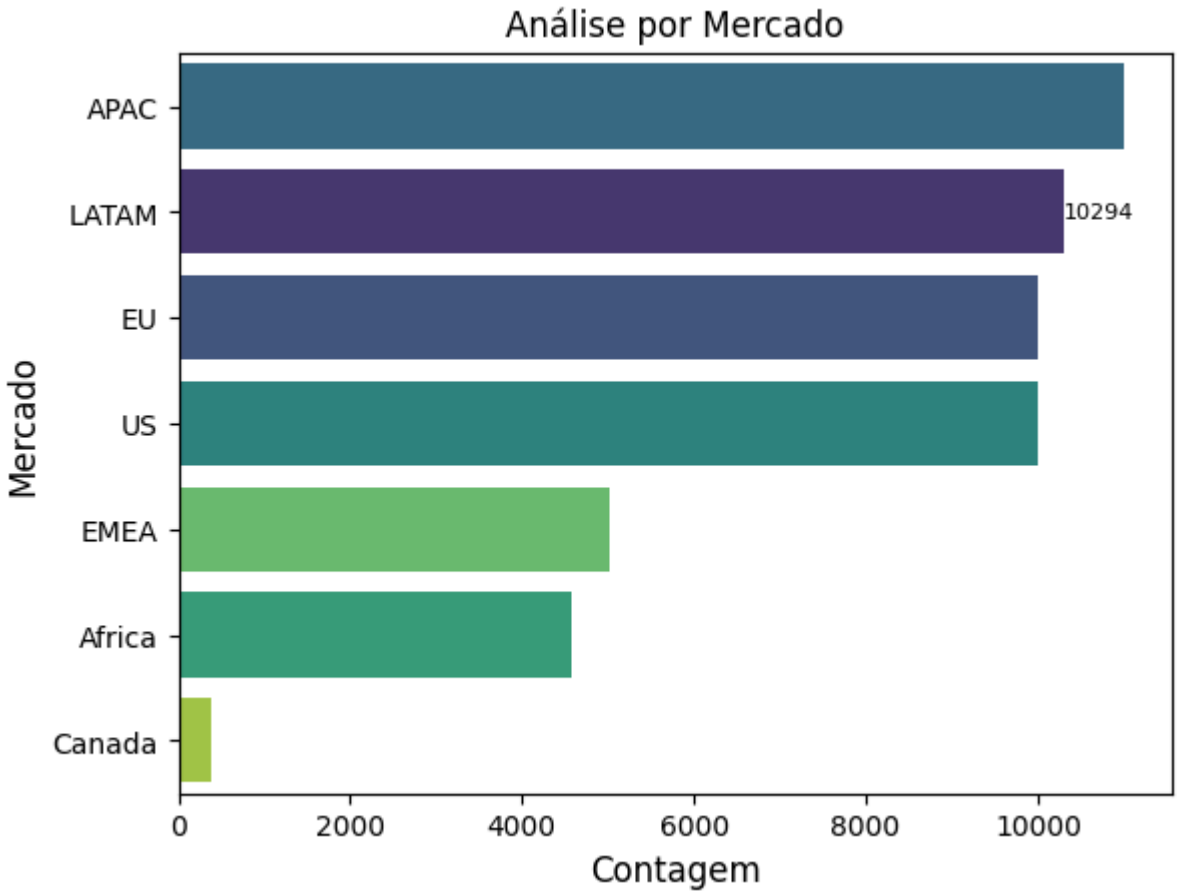

Gráfico de barras - seaborn.barplot()

In [57]:
```
comercio[['category', 'profit']]
```

Out[57]:

	category	profit
0	Office Supplies	4.56
1	Furniture	90.72
2	Furniture	54.08
3	Office Supplies	4.96
4	Office Supplies	11.44
...	...	...
51285	Office Supplies	3.42
51286	Technology	18.42
51287	Office Supplies	20.88
51288	Office Supplies	33.84
51289	Office Supplies	12.96

51290 rows × 2 columns

In [67]:
```
# Separa o data frame de acordo com as variáveis category e profi, e então agrupa d
comercio_agrupado = comercio[['category', 'profit']].groupby(by=['category']).mean(
comercio_agrupado
```

Out[67]:

	profit
category	
Furniture	28.878567
Office Supplies	16.578961
Technology	65.454958

In [72]:
```
comercio_agrupado = comercio_agrupado.sort_values(by=['profit'], ascending=False)
comercio_agrupado.reset_index() # coloca os índices na tabela
```

Out[72]:

	category	profit
0	Technology	65.454958
1	Furniture	28.878567
2	Office Supplies	16.578961

In [75]:
```
# Gerando o gráfico de barras

sns.barplot(data=comercio_agrupado, x='category', y='profit',hue="category", palett
plt.title("Lucro Médio por Categoria")
plt.xlabel('Categorias',fontsize=12)
```

```
plt.ylabel('Lucro',fontsize=12)
plt.show()
```

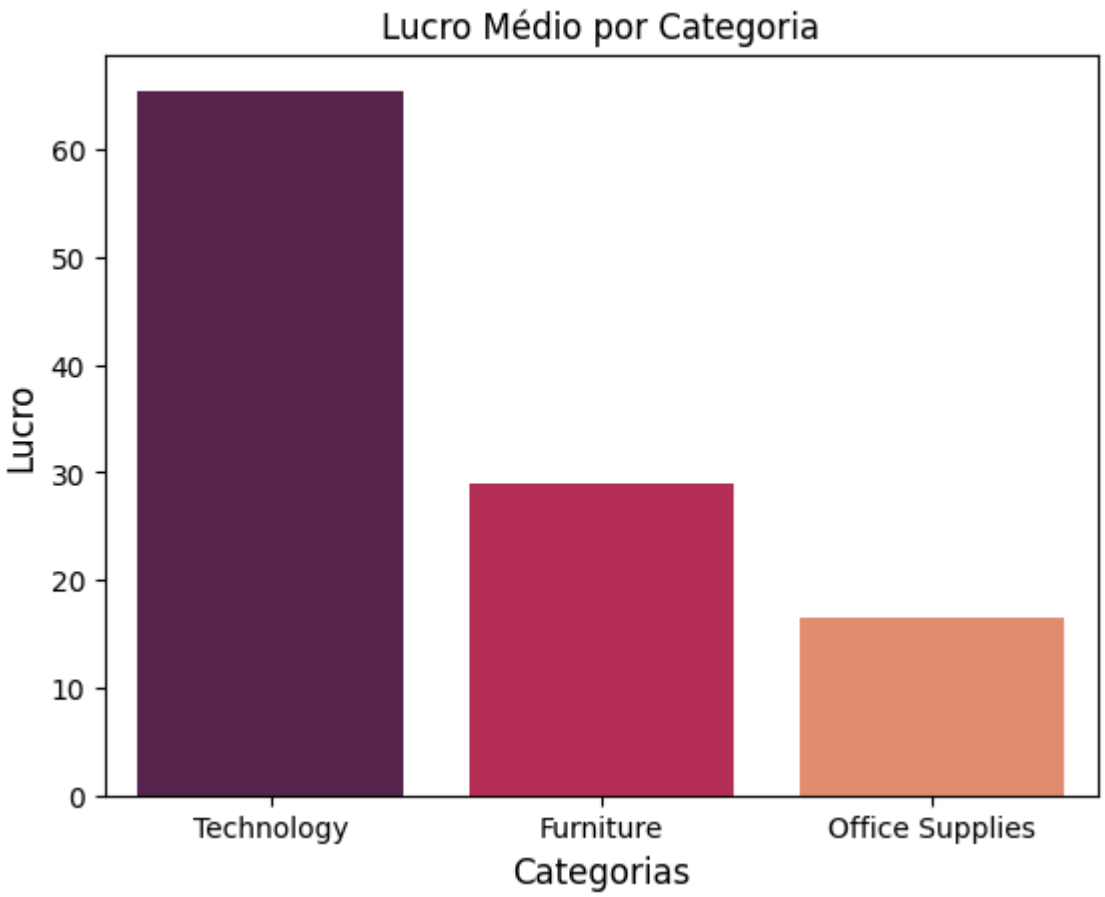

Gráfico de pizza - plt.pie()

In [82]:
```
# aqui ele cria uma tabela de frequências relativas utilizando normalize = True, e
pizza = pd.crosstab(index = comercio['segment'], columns = 'segmento', normalize =
pizza
```

Out[82]:

col_0	segmento
segment	
Consumer	0.517021
Corporate	0.300819
Home Office	0.182160

In [83]:
```
pizza = pd.crosstab(index = comercio['segment'], columns = 'segmento', normalize =

plt.pie(pizza['segmento'],
        labels = pizza.index,
        colors = sns.color_palette('pastel'),
        autopct='%.0f%%', # nº de casas decimais
        textprops={'fontsize': 10}, # tamanho da fonte
```

```
        pctdistance = 0.5) # posição dos percentuais
plt.title('Análise por Segmento')
plt.show()
```

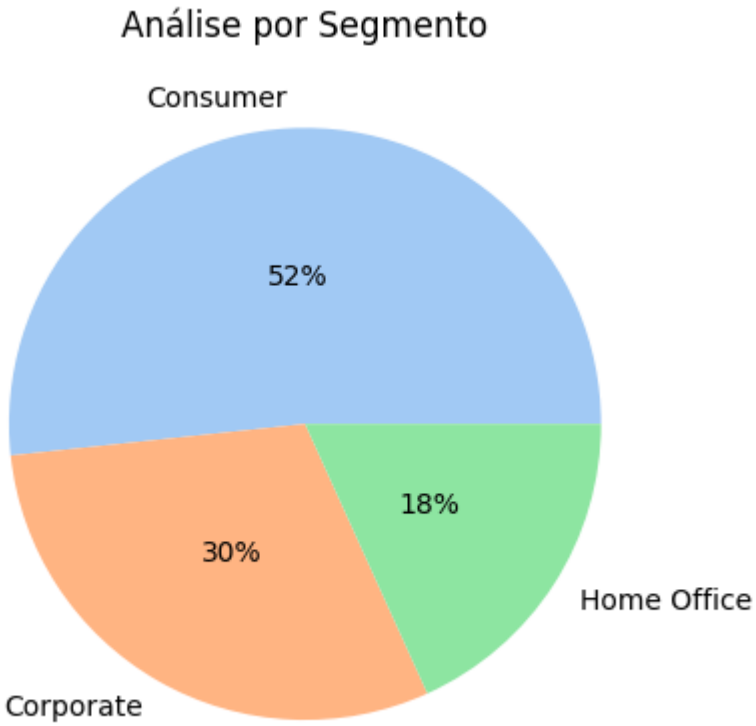

Histograma - seaborn.histplot()

No dataframe "comercio" há uma coluna chamada sales, iremos fazer um histograma com ela.

resumo de alguns parâmetros:

- `data` : DataFrame, array, or list of arrays. This is the data source.
- `x, y` : Names of variables in data or vector data, optional. These parameters specify the data for the x and/or y axis.
- `hue` : Name of variables in data or vector data, optional. This parameter is used to group data by different colors.
- `color` : Matplotlib color, optional. Sets the color of the bars.
- `bins` : Number of bins or the specific bin edges. Determines the number of bins for the histogram.
- `binwidth` : Width of each bin.
- `kde` : Boolean, optional. If True, add a kernel density estimate.
- `alpha` : Float, optional. Sets the transparency level of the bars.

In [86]:
```
hist_vendas = comercio[comercio['sales'] < 1000]
```

```
ax = sns.histplot(data=hist_vendas, x="sales", bins=30)
plt.xlabel('Valor das Vendas',fontsize=12)
plt.ylabel('Frequência',fontsize=12)
plt.show()
```

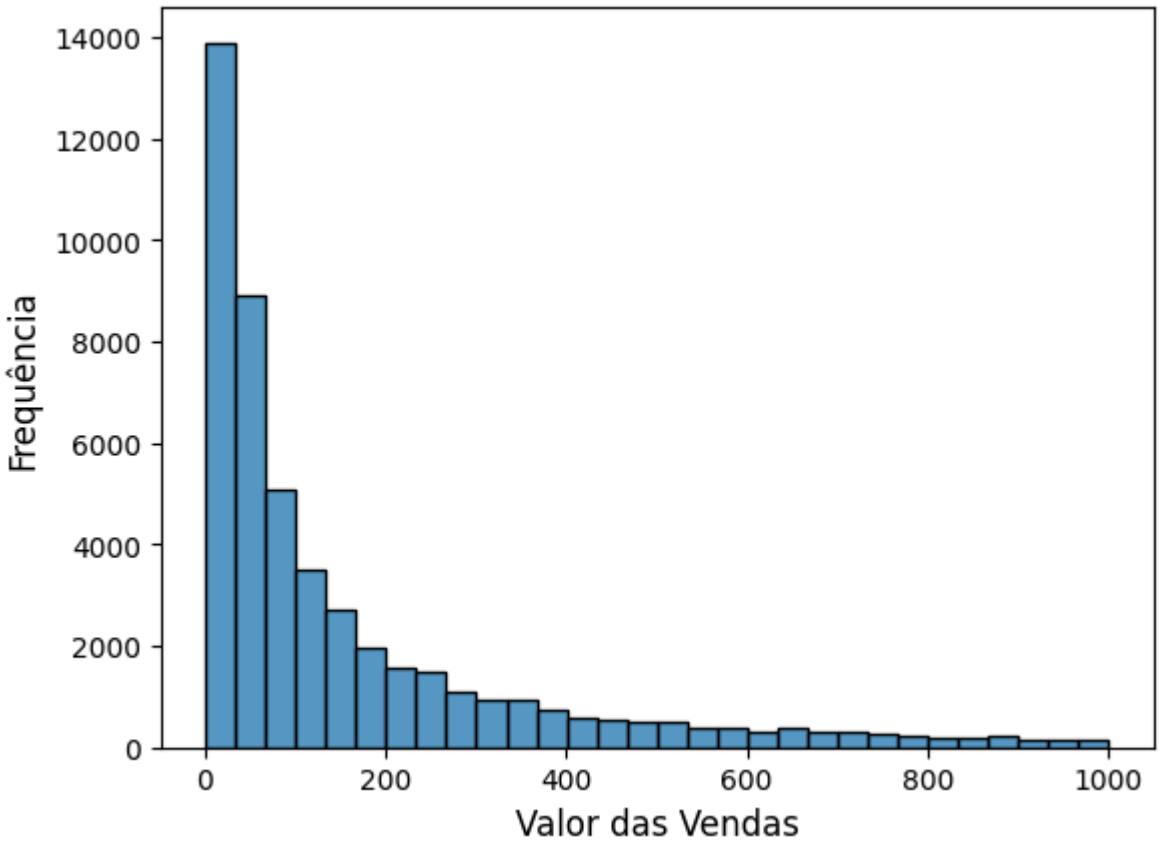

In [94]:
```
# Detalhando um pouco mais o gráfico

ax = sns.histplot(data = hist_vendas, x = "sales", bins=range(0,1100,100), color =
ax.bar_label(ax.containers[0], fontsize=8) # coloca o número de contagens em cima d
plt.xlabel('Valor das Vendas',fontsize=12) # label do eixo x
plt.xticks(ticks=np.arange(0,1100,100))  # define os limites do gráfico
plt.ylabel('Frequência',fontsize=12) # label do eixo x
plt.show()
```

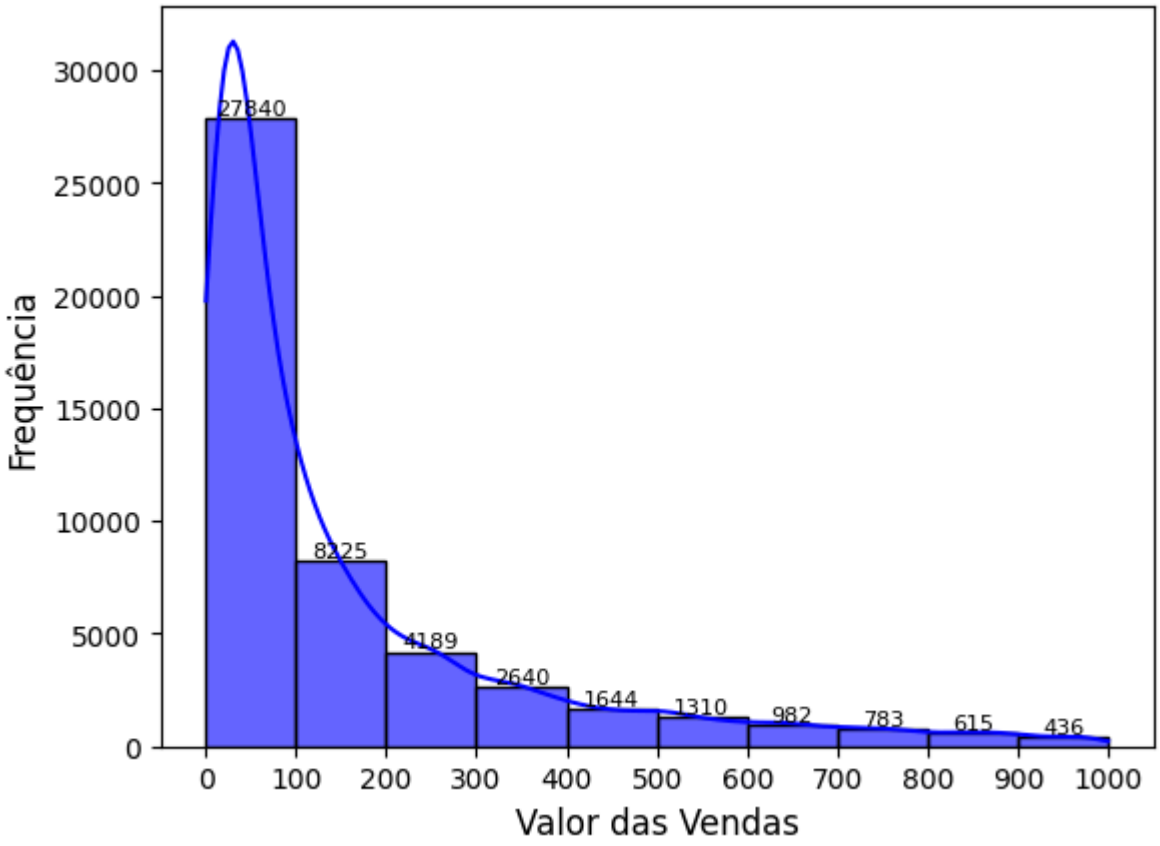

Gráfico de pontos - seaborn.scatterplot()

Alguns parâmetros:

- `data` : DataFrame, array, or list of arrays. The data source.
- `x, y` : Names of variables in data or vector data, optional. These specify the data for the x and y axes.
- `hue` : Name of variables in data or vector data, optional. Group data by different colors.
- `size` : Name of variables in data or vector data, optional. Group data by different sizes.
- `style` : Name of variables in data or vector data, optional. Group data by different markers.

In [97]:
```
# Para começar vamos importar a seguinte base de dados

atlas_ambiental = pd.read_excel("(2) atlas_ambiental.xlsx")
atlas_ambiental[0:5] # visualizando parte da base de dados
```

Out[97]:

	cód_ibge	distritos	renda	quota	escolaridade	idade	mortalidade	txcresc	caus
0	1	Água Rasa	1961	34.62	7.6	32	13.86	-1.840000	
1	2	Alto de Pinheiros	4180	75.96	8.4	33	8.68	-2.520000	
2	3	Anhanguera	1093	4.50	5.8	23	15.36	18.120001	
3	4	Aricanduva	1311	21.02	6.8	27	18.43	-1.070000	
4	5	Artur Alvim	1248	15.91	7.0	27	19.73	-1.400000	

In [107…

```
sns.scatterplot(data=atlas_ambiental, x="renda", y="escolaridade", size="idade")
plt.title("Indicadores dos Distritos do Município de São Paulo")
plt.xlabel('Renda',fontsize=12)
plt.ylabel('Escolaridade',fontsize=12)
plt.show()
```